


Phillip B. Ströbel & Felix K. Maier

Cicero Digital



Automatische Analyse eines antiken Briefwechsels

Februar 2026

ver. 2026.a

Inhaltsverzeichnis

1	Einführung	5
1.1	Cicero	6
1.2	Ciceros Briefe	7
1.3	Aufbau des Readers	9
2	Der Brief als Datenbasis	11
2.1	Briefe in der Antike	11
2.2	Die Datengrundlage bei Cicero	13
2.2.1	Perseus	14
2.2.2	Datenformat: XML	14
2.3	Erste Verarbeitungsschritte	23
2.3.1	Dateien finden	23
2.3.2	TEI und Namespace	23
2.3.3	Was ist ein Brief im XML?	24
2.3.4	Metadaten extrahieren	24
2.3.5	Absender und Empfänger als Heuristik	24
2.3.6	Vom XML zur Tabelle	25
2.3.7	Datenset exportieren	27
2.3.8	Erste statistische Checks	28
2.3.9	Visualisierung	28
2.3.10	Fazit	29
	Litertaurverzeichnis	32

Session

1

Einführung

Lernziele Session 1: Einführung

Verstehen Du verstehst, wie digitale Methoden historische Fragestellungen an antiken Texten ermöglichen, strukturieren und zugleich begrenzen, und kannst deren Voraussetzungen und Annahmen benennen.

Analysieren Du kannst Ciceros Briefe sowohl als Texte als auch als Daten analysieren und zwischen *close reading* und skalierenden Verfahren reflektiert wechseln.

Anwenden Du kannst digitale Analyseverfahren (z.B. Metadaten, einfache Korpusanalysen, Netzwerke, Mustererkennung) gezielt einsetzen und mit historischer Kontextualisierung verbinden.

Bewerten Du kannst digitale Ergebnisse kritisch beurteilen, insbesondere im Hinblick auf Selektion, Überlieferung, Modellierungsentscheidungen und Interpretationsgrenzen.

Erzeugen Du kannst eine eigenständige, methodisch transparente Analyse zu Ciceros Briefen erarbeiten und in geeigneter Form präsentieren (z.B. als Wiki-Beitrag), inklusive nachvollziehbarer Fragestellung, Datenbasis und Interpretation.

Disclaimer: Dieser Reader hat nicht die Absicht, ein vollständiges historiographisches Porträt von Cicero nachzuzeichnen und wiederzugeben. Wir beschränken uns in Bezug auf die Nennung historischer Quellen und relevanter Forschungsbeiträge auf ein Minimum. Vielmehr geht es in diesem Reader darum, computerlinguistische Methoden auf den Briefwechsel anzuwenden. Daraus resultierende Ergebnisse werden nur vereinzelt in den Kanon der bereits bestehenden Forschung eingeordnet. Nichtsdestotrotz sind wir für Hinweise zu Fehlern sehr dankbar!

1.1 Cicero

Marcus Tullius Cicero (106–43 v. Chr.) war einer der bedeutendsten Persönlichkeiten in der Zeit der sich dem Ende nahenden Römischen Republik. Aber warum eigentlich? Jeder und jedem ist der Name eigentlich ein Begriff und durch seine zahlreichen überlieferten Werke ist Cicero als Person eigentlich gut fassbar. Trotzdem könnten die allermeisten wohl “nur” sagen, dass er ein berühmter Schriftsteller der lateinischen Klassik gewesen sei. Und das wissen wohl auch nur gerade diejenigen, welche in ihrer schulischen Laufbahn in den Genuss von Lateinunterricht gekommen sind (und lange genug dabei geblieben sind, bis der obligate Cicero-Text übersetzt werden musste).

Doch Cicero war weitaus mehr als bloss ein Schriftsteller. Schaut man sich einige seiner Schriften an, die bis in unsere Zeit überdauerten, wird schnell klar, dass Cicero in vielen Fachrichtungen unterwegs war. Viele seiner Reden (z. B. aus dem Jahre 66 v. Chr. mit dem Titel *De imperio Cn. Pompei*, “Für den Oberbefehl des Pompeius”) hielt er im Senat – als Politiker. Dafür finden wir auch andere Quellen, wie beispielsweise eine Inschrift aus der Hafenstadt Ostia, die verkündet, dass unter dem Konsulat Ciceros (63 v. Chr.) *muros* (“Mauern”) und *portas* (“Pforten”) errichtet wurden (siehe Abb. 1.1). Das Werk *Pro Archia* (“Für Archias”) stellt eine von Cicero im Jahre 63 v. Chr. gehaltene Verteidigungsrede dar, in welcher wir Cicero die Rolle als Anwalt für den Dichter Archias einnehmen sehen. Sein Text *De Divinatione* (“Über die Wahrsagung”), der kurz vor seinem Tod um 44 v. Chr. entstand, vermittelt uns Cicero als Philosophen. 55 v. Chr. entstand noch Ciceros *De oratore* (“Über den Redner”), aus welchem Cicero auch als Rhetoriker hervorgeht.

Und schliesslich gibt es als überlieferte Quellen über 900 Briefe (mehr Details im Unterkapitel 1.2 und generell im Kapitel 2). Hier schlüpft Cicero zwar auch in die im vorherigen Absatz erwähnten Rollen, aber wir erfahren noch viel mehr über Cicero als Person. Im Briefwechsel begegnet uns Cicero nämlich auch als Bruder des Quintus Tullius Cicero (102–43 v. Chr., in *Epistulae ad Quintum fratrem*, “Briefe an den Bruder Quintus”), Vater, Ehemann und guter Freund (in *Epistulae ad familiares*, “Briefe an seine Freunde”). Besonders ausführlich sind die Kontakte mit Atticus (110–32 v. Chr., *Epistulae ad Atticum*) und einem gewissen Marcus Iunius Brutus (85–42 v. Chr., *Epistulae ad M. Brutum*), der als Mitverschwörer gegen und Mitmörder des **Caesar** in die Geschichte einging. Damit hätten wir im Übrigen bereits die vier Teilkorpora des überlieferten Briefkorpus aufgezählt, mit denen wir uns in diesem Reader beschäftigen werden. Sie seien der besseren Übersicht wegen hier nochmals genannt:

- *ad Quintum fratrem*
- *ad familiares*
- *ad Atticum*
- *ad M. Brutum*



Abbildung 1.1 Inschrift aus Ostia, die von Cicero als Konsul (auf der Inschrift als Abkürzung COS wiedergegeben) zeugt (CIL XIV, 4707).

Transkription: *Senatus populusque romanus / coloniae ostiensium muros et portas fecit / M(arcus) Tullius Cicero co(n)s(ul) fecit locavitque / P(ublius) Clodius Pulcher tr(ibunus) p(opu)l(us) consummavit et probavit / portam vetustate corruptam [...] et [...] rv*

Übersetzung: Der Senat und das Römische Volk haben für die Kolonie der Ostiensier Mauern und Tore errichtet. Der Konsul Marcus Tullius Cicero hat (den Bau) veranlasst und vergeben. Der Volkstribun Publius Clodius Pulcher hat (ihn) vollendet und abgenommen. (Dies betraf) ein durch das Alter zerstörtes Tor ... und ...

1.2 Ciceros Briefe

Es liegt in der Natur des Mediums “Brief,” dass sich Cicero im Briefwechsel anders darstellt als in seinen übrigen Schriften: Der Umgangston kann, vor allem in Austausch mit seinen engsten Kontakten, schon als kolloquial bezeichnet werden (Manuwald, 2025, S. 797). Schon in Werken der Antike spricht Demetrios von Phaleron (360–280 v. Chr.), dem die Schrift *περὶ ἐρμηνείας* (“Über den Stil”) zugeordnet wird (was allerdings umstritten ist), in der Charakterisierung von Briefen davon, dass jeder Autor ein Abbild seiner Seele im Brief hinterlässt (siehe dazu auch Müller, 1980, der vom “Spiegel der Seele” spricht). Dieser Meinung ist im Übrigen auch Mommsen (1856, S. 572 ff.), der von der Korrespondenz sagt, dass sie am ehesten noch das Bild von Cicero widergebe, ansonsten aber einen ziemlich negativen Eindruck von Cicero zu haben scheint. Vor diesem Hintergrund und der Tatsache, dass die Briefe Ciceros ein so breites Themenfeld abdecken, ist es verwunderlich, dass auf dessen deutschen Wikipedia-Seite den Briefen nur ein ganz kleiner Abschnitt gewidmet ist.

Was für ein Schatz italienische Dichter und Geschichtsschreiber Francesco Petrarca (1304–1374 n. Chr.) gehoben hatte, als er 1345 in Verona eine Abschrift von Ciceros Privatbriefen entdeckte, war ihm wohl kaum bewusst. Er schrieb die Briefe ab (und verfasste selbst zwei Briefe an Cicero (Egelhaaf-Gaiser, 2025, S. 9)) und sorgte so dafür, dass sie wieder in den Umlauf kamen. Dabei war Petrarca vom “neuen” Cicero, den er durch den Briefwechsel nun kennenlernen konnte, gelinde gesagt, enttäuscht. Verkörperte Cicero vor der Lektüre der Briefe für Petrarca durchaus ein Idol, so stellte sich Cicero für ihn in der Korrespondenz als überaus wankelmütig und, in Petrarcas Worten, unmännlich dar (Viertel, 1879, S. 8).

Nichtsdestotrotz dienten Ciceros Briefe vortan auch als Quelle der Inspiration. So beeinflussten sie die Humanismus-Bewegung während der ab dem 14. Jhdt. einsetzenden Renaissance massgebend (Walter, 2014, S. 43). Als solches

sicherte Petrarcas Einsatz das Überleben der römischen Brieftradition. Dies hatte zur Folge, dass die Cicero-Briefe seit deren Wiederentdeckung immer wieder Gegenstand der Forschung innerhalb verschiedener Disziplinen wie zum Beispiel in der altphilologischen Briefforschung, der klassischen Geschichtsforschung oder auch der Philosophie wurden. Einen ernsthaften Aufschwung erlebte die altphilologische Briefforschung jedoch erst in den 1980er Jahren, da Konzepte aus den Neuphilologien grossflächig auf die Altphilologie übertragen wurden (Egelhaaf-Gaiser, 2025, S. 5).

Die über 900 erhaltenen Cicero-Briefe sind nicht zuletzt darum interessant, weil eine Vielzahl davon wohl nicht für die Publikation vorgesehen war. Es ist selbstverständlich, dass man anders schreibt, wenn man weiss, dass nicht nur diejenige Person einen Brief lesen wird, an welche der Brief adressiert ist, sondern wohl noch einige 1'000 weitere. Davon zeugt, dass in vielen Briefen Grussformeln, Aufenthaltsorte und Informationen über die Gesundheit einer Reihe von Personen enthalten sind, was für zu publizierendes Material unüblich war (Manuwald, 2025, S. 799). Darüber hinaus wurden die Briefe nicht mehr zu Lebzeiten Ciceros publiziert, sondern erst posthum, wohl zu Zeiten Augustus' und Neros (Manuwald, 2025, S. 796). Dass Teile des Briefwechsels über 100 Jahre nach Ciceros Tod veröffentlicht wurden, heisst auch, dass nicht der später freigelassene Sklave und Sekretär Ciceros, Marcus Tullius Tiro (103–3 v. Chr.), die Briefe in Umlauf brachte, sondern ein nicht bekannter Editor, und das anhand weitgehendst unbekannter Kriterien (White, 2010, S. 61).

Für die Computerlinguistik sind Ciceros Briefe ein Glücksfall. Sie stellen eine Art riesige Spielwiese dar, auf welcher wir uns mit verschiedensten Methodiken "austoben" können. Dass bereits sehr viel Forschung zum Cicero-Briefwechsel vorliegt, ist dabei kein Hindernis. Vielmehr bieten die bereits bestehenden Erkenntnisse zur Korrespondenz Inspiration und valide Ausgangspunkte. So können bereits aufgestellte Theorien mit automatischen Verfahren überprüft und verifiziert oder verworfen werden. Aber auch neue Erkenntnisse lassen sich durch computerlinguistische Methoden gewinnen. Ein Forschungsdesiderat, das wiederholt genannt wird, ist die Netzwerkanalyse (Egelhaaf-Gaiser, 2025, S. 26). Damit werden wir uns im Kapitel ?? beschäftigen. Mit wem interagierten Cicero und sein persönliches Umfeld? Varianten des sogenannten *Distant Readings* (Moretti, 2013) (siehe Kapitel ??) helfen uns dabei, einen Überblick zu gewinnen. So spüren wir das Netzwerke Ciceros auf. Dazu verwenden wir auch die sogenannte *Eigennamenerkennung* (Eng.: *Named Entity Recognition*). Diese ist ein automatisches Verfahren, welche automatisch Personen, Orte, Institutionen und Toponyme im Briefwechsel markiert. Wenden wir darüber hinaus die *Sentimentanalyse* an, also das Identifizieren von Emotionen, können wir erschliessen, in welchen Beziehungen die Personen zueinander standen. Eine zusätzliche Auswertung des verwendeten Vokabulars, konkreter aber noch der Sprache an sich, wird uns zeigen, wie sich Cicero und seine Korrespondentinnen ausdrückten. Die Sprache wird im Allgemeinen von Interesse sein und so erhalten auch altphilologische Fragestellungen Einzug in unseren Themenstrass. Cicero hat beispielsweise immer wieder griechische Wörter in seinen Briefen eingebaut, also sogenanntes Code-Switching betrieben. Wann macht er das in der Regel? Wie häufig ist das

generell und mit welchen Motiven tut er das? Eine automatische Auswertung kann uns dabei helfen. Und zuguterletzt (obwohl das Ende der Fahnenstange noch lange nicht erreicht ist): Lassen sich die Briefe automatisch übersetzen, da die Lateinkenntnisse vieler Historiker:innen immer weiter abnehmen? Wenn ja, wie gut? Mit solchen Herangehensweisen hoffen wir, mit diesem Reader die Geschichtswissenschaften und die Computerlinguistik in Einklang zu bringen und damit die Geschichtsforschung als solche weiterzubringen.

1.3 Aufbau des Readers

Zu Beginn jedes Kapitels werden jeweils die Lernziele erklärt. Als Nächstes folgt der Inhalt, manchmal ergänzt durch Exkurse oder Kompakt-Abschnitte.

Lernziele Session 1: Einführung

Die Lernziele sind in blauen Boxen.

Exkurs

Die Exkurse sind in grünen Boxen.

Kompakt

Die Kompakt-Abschnitte sind in roten Boxen.

Wir orientieren uns im Kurs am Buch *Cicero in Letters* von White (2010). White nähert sich Cicero, ausgehend vom Briefwechsel selbst, in unterschiedlichsten Facetten. So beleuchtet er im ersten Teil seines Buches den Kontext, in welchem Ciceros Briefe entstanden sind, und erläutert die Rolle der schriftlichen Kommunikation sowie deren Hürden im Allgemeinen. Hier geht es darum, welche Rolle die Boten spielten, die die Briefe überbracht haben, und wie und wer den Briefwechsel so ediert hat, wie er uns heute vorliegt. Im zweiten Teil geht White zur Analyse des Inhaltes über. Hier kommen diskurslinguistische Elemente zum Tragen: Wie kommuniziert Cicero mit wem? Was spielt die literarische Kultur in der Kommunikation eine Rolle? Weiter geht White auch Ciceros ratgebende Korrespondenz ein. Hier interessieren ihn vor allem soziolinguistische Aspekte. Zuguterletzt widmet sich White auch dem Thema, wie Ciceros Rolle als politische Führungspersönlichkeit im Briefwechsel durchdringt. Somit liefert Whites Beitrag einen spannenden Einblick in Ciceros Briefpersona, die wir so anhand seiner Vorleistungen auch digital erschliessen können. Zeigen sich beispielsweise in seinen Briefen, in denen er Ratschläge gibt, gewisse Emotionen, oder erteilt er diese nüchtern und sachlich? Wo wird Cicero überhaupt emotional? Die sogenannte automatische *Sentimentanalyse* kann uns dabei unterstützen.

Als ergänzende Lektüre empfehlen wir *Cicero* (Manuwald, 2014) und das *Handbuch Brief: Antike* (Becker et al., 2025). Die Themen, die Peter White in seinem Buch zum Briefwechsel Ciceros behandelt, bilden die Grundlage der Struktur des Readers. So sind den Kapiteln Whites der Reihe nach die wichtigsten Themen entnommen, die man digital aufbereiten und ergründen kann. Somit

bietet es sich an, White und diesen Reader parallel zu lesen.

Aufgrund der aus dem Buch von White erschlossenen Inhalte sind die ab Kapitel 2 aufgeführten Beispiele entstanden. Diese sind so gegliedert wie in Code-Beispiel 1.1 dargestellt. Sie sollten die Funktionsweise des Besprochenen illustrieren. Am besten schreibt man die Code-Beispiele kurz ab, damit man die Konzepte bereits zum ersten Mal festigt. Zur Not können die Beispiele aber auch so in Jupyter Notebooks kopiert und ausgeführt werden.

Code-Beispiel 1.1 Beispiel eines Code-Abschnittes

```
print('Marcus Tullius Cicero te salutat!')  
Marcus Tullius Cicero te salutat!
```

Die vollständigen Jupyter Notebooks sind auf unserer [JupyterLite-Instanz](#) abgelegt. Dort finden sich auch sämtliche Daten. Der Code ist in dieser Browser-Umgebung vollständig ausführbar.

Nebst den Daten und Jupyter Notebooks möchten wir auch auf das [Wiki](#) aufmerksam machen, das im Zuge der Durchführung des Kolloquiums [Cicero Digital](#) am [Historischen Seminar](#) der [Universität](#) Zürich entstanden ist. Dort gestalteten die Studierenden in Partnerarbeit eine Wiki-Seite. Ziel war es, mit dem Cicero-Briefwechsel als Grundlage eine historische Fragestellung auszuarbeiten, welche mit komputationellen Methoden erschlossen werden konnte. Das Resultat ist eine Vielfalt von neuen Perspektiven, die sich aufgrund des andersartigen Zugangs auftun.

Der Brief als Datenbasis

Lernziele Session 2: Der Brief als Datenbasis

Verstehen Du verstehst, warum Ciceros Briefe als *Datenbasis* und nicht nur als historische “Quelle” behandelt werden können, und was White mit den *constraints and biases* der Überlieferung und Sammlung meint.

Analysieren Du kannst in einem Briefkorpus (Perseus) die für eine strukturierte Analyse relevanten Informationstypen identifizieren (z.B. Absender, Empfänger, Datum, Ort) und typische Probleme der Briefe als Daten benennen (Unvollständigkeit, Uneindeutigkeit, Editionsentscheidungen).

Anwenden Du kannst Briefe aus dem Perseus-Korpus in eine tabellarische Struktur überführen und ein einfaches Metadaten-Schema praktisch ausfüllen (mindestens Absender, Empfänger, Datum, Ort) sowie getroffene Normalisierungen und Entscheidungen dokumentieren.

Bewerten Du kannst die Aussagekraft deiner Metadaten kritisch einschätzen: Welche Felder sind stabil, welche unsicher? Wie beeinflussen *constraints and biases* (White) spätere Visualisierungen und Auswertungen?

Erzeugen Du kannst ein kleines, reproduzierbares Mini-Dataset (Tabelle + kurze Dokumentation) erstellen, das als Grundlage für weitere digitale Analysen dient (z.B. erste Diagramme oder spätere Netzwerk- und Raumanalysen).

2.1 Briefe in der Antike

Die Epistolografie – vom Griechischen *ἐπιστολή* (Brief) und *γράφειν* (schreiben, zeichnen), was aber als -kunde aufgefasst werden muss – ist also die Briefkunde, die Wissenschaft vom Briefeschreiben. Dabei geht sie, wie wir in Unterkapitel 1.2 gesehen haben, bereits bis in die Antike zurück.

Umso erstaunlicher ist es, dass gemäss Egelhaaf-Gaiser (2025, S. 5) die Auseinandersetzung mit der ‘Literaturgattung’ Brief in der altphilologischen Forschung erst seit den 1980er-Jahren an Attraktivität gewonnen hat. Dennoch bleibt es vorerst zu definieren, was man unter ‘Brief’ im eigentlichen Sinne versteht. Man würde doch meinen, dass diese Frage im 21. Jahrhundert geklärt ist. Sieht man aber genauer hin, eröffnen sich auch hier Schwierigkeiten der Begriffsdefinition ‘Brief’.

Die ersten Assoziationen, die einem vor das innere Auge treten, wenn man an einen Brief denkt, sind wohl ein (von Hand?) geschriebenes Dokument, das in einem Briefumschlag von einer Person A–dem Sender–einer anderen Person B–dem Empfänger–übermittelt wurde. Würden wir das als Briefdefinition annehmen, böte eine solche Festlegung für die Moderne bereits genügend Angriffsfläche: Ist eine Nachricht auf WhatsApp ein Brief? Was ist mit dem Mailverkehr? Und wie sieht das mit Beiträgen auf Social-Media-Kanälen aus? Wie öffentlich können Briefe sein? Welche Elemente müssen sie enthalten, um als Brief zu gelten? Und was ist nur optional?

Zumindest mit Blick auf die Antike gestaltet sich die Frage nach dem Medium etwas einfacher, obwohl es auch damals bereits eine gewisse Vielfalt gab. So konnten Briefe auf *Ostraka* (also Tonscherben) oder auf Papyrus, Holz- oder Tontafeln übermittelt werden. Diese Liste ist sicher nicht abschliessend und um die eigentliche Materialität soll hier nicht zum Thema werden. Ähnlich schwierig wie für ‘moderne’ Briefe gestaltet sich jedoch die Frage, wie antike Briefe inhaltlich definiert und klassifiziert werden können.

Neben (vermutlicherweise) Demetrios finden wir auch bei anderen antiken Autoren Hinweise für eine Gattungsdefinition. So schreibt zum Beispiel der Kirchenvater Augustinus (354–430 n. Chr.) in seinen *Überarbeitungen*, dass sein Buch *Ad inquisitiones Ianuarii* (“Auf die Anfragen des Ianuarius”) eigentlich ein Brief ist, da zu Beginn steht, wer an wen schreibt (*retr.* 2,20). So finden wir “Auf die Anfragen des Ianuarius” heute nicht unter seinen Werken, sondern in seinem Briefwechsel. Augustinus bediente sich insofern bestimmter Kriterien (wie etwa dem Vorhandensein von Absender und Empfänger), um seine Schriften zu klassifizieren.

Briefe wurden von antiken Autoren aber auch noch genauer umschrieben. So treffen wir immer wieder auf den Ausdruck des “halben geschriebenen Dialog” (in der Antike in Demetr. *eloc.* 223 f., aufgegriffen ebenfalls bei Seibert, 2025, S. 226 und Ebbeler, 2010, S. 468) zwischen zwei Personen *in absentia* (Cic. *Phil.* 2,7). Hierbei ist das Konzept der Hälfte entscheidend: denn es ist gerade bei den Cicero-Briefen so, dass die eine Hälfte, und damit ist hier die grösstenteils an Cicero gerichtete Korrespondenz gemeint, fehlt. Das ist für die Antike typisch (Hoskin, 2025, S. 88). So finden wir im Cicero-Briefwechsel nur etwa gerade 10% an Briefen, in denen Cicero als Empfänger fungierte (White, 2010, S. 6). Diese Situation wurde nur dann bereits in der Antike entschärft, wenn die Briefe von Beginn an zur Publikation gedacht waren, wie das bei **Plinius dem Jüngeren** (61/62–113/115 n. Chr.).

Die Briefe Ciceros sind aber auch ganz generell eine Quelle für die Brieftheorie (Becker & Blom, 2025, S. 134). So widmet sich beispielsweise Schwitter

(2017) den Themen Beileid und Trost–auf das wir im Übrigen in Kapitel ?? nochmals zurückkommen werden–in den *Epistulae ad familiares*, insbesondere bei Todesfällen (*de morte*). Schwitter arbeitet heraus, wie Briefschreiber in der Antike ihre Anteilnahme verschriftlichten und welche Auswirkungen das auf die Empfänger gehabt haben muss. Die Briefe, in welchen vom Tod von Ciceros Tochter Tullia 45 v. Chr. die Rede ist, geben deshalb besondere Einblicke in die Biographie von Cicero, wie das im Übrigen auch für viele andere Briefe der Fall ist (Hoskin, 2025, S. 93).

Bei der Interpretation ist jedoch Vorsicht geboten. Bereits Schwitter merkt an, dass “die Sammlung der *Epistulae ad familiares* lediglich einen unvollständigen Einblick in die Praxis brieflicher Trost- und Beileidsschreiben *de morte* bietet” (2017, S. 377), also kein abschliessendes Urteil über die Trauerbewältigung und den Trost als solches möglich ist. Schliesslich kamen die Briefe auch in einer mehr oder weniger aufwändig editierten Version auf uns, wobei wir über einiges im Dunkeln sind: Wir wissen nicht, *wer* das Cicero-Briefkorpus kompiliert hat. Wir wissen nicht, *wie* die unbekannten Editoren in den Publikationsprozess eingegriffen haben. Wie viel (wenn überhaupt) wurde am Text geändert? Wir wissen nicht, wie oft diese Publikationen weiter abgeschrieben und verändert worden sind.

Und trotzdem erfahren wir aus Ciceros Korrespondenz so viel über den antiken Brief wie selten irgendwo, da er oft davon spricht “wann und nach welcher Zeitspanne ein Brief ihn erreicht habe, auf welchem Wege er Briefe abschicke oder erhalte, ob die Zustellung gewährleistet sei, da Briefe unterwegs verloren gehen, geöffnet oder abgefangen werden oder Kuriere nicht zuverlässig sein könnten, oder dass er zur Sicherheit mit eigener Hand oder auf Griechisch schreibe” (Manuwald, 2025, S. 799). In der Interaktion zweier Abwesener, wie Cicero gemäss Rühl (2025, S. 328) zu sagen pflegte, kristallisieren sich die Beziehungen zwischen Absendern und Empfängern heraus, welche der Absender weiter zu formen versuchte, nämlich durch das Aufzeigen von “Status, Bildung, Verbindungen und Einflussmöglichkeiten” (Seibert, 2025, S. 230).

Es ist deshalb unabdingbarerweise der Inhalt des Briefes an die Form auf der einen Seite und die Funktion auf der anderen Seite geknüpft. Das heisst konkret, dass die von den Verfassern verwendete Sprache ein Ziel verfolgte, beispielsweise das von Schwitter (2017) untersuchte Trösten des physisch nicht präsenten Gegenübers. Die literarische Form des Briefes kann jedoch unterschiedlich ausgeprägt sein. Das Spektrum reicht von strikt historisch bis zu poetisch, wobei die Grenzen fließend sind (Ebbeler, 2010). Um Form und Funktion auf den Grund gehen und jedem Brief seine Wirkung zuordnen zu können (Egelhaaf-Gaiser, 2025, S. 10), müssen wir zuerst an die Inhalte gelangen. Das Briefkorpus Ciceros ist längst auf verschiedenen Webseiten im Netz zu finden. In den nächsten zwei Unterkapiteln gehen wir auf die ersten Vorverarbeitungsschritte ein.

2.2 Die Datengrundlage bei Cicero

Die Datengrundlage, das heisst, die Menge an Briefen von Cicero, die uns überliefert sind, ist für antike Verhältnisse eigentlich als “gut” einzustufen. Die

Rede ist oft davon, dass die Spätantike ergiebiger sei. Das mag für die Anzahl der Korrespondenzen zutreffend sein—man denke an Augustinus, **Gregor von Nazianz** (329–390 n. Chr., über 200 überlieferte Briefe), oder **Isidorus von Pelusium** (360–431/451 n. Chr., von ihm kennen wir über 2'000 Briefe), um nur einige zu nennen—, aber vergleicht man beispielsweise diejenige des Augustinus mit der von Cicero, kann Augustinus lediglich mit etwas mehr als 300 Briefen aufwarten.

Ganz abgesehen von der Menge an Briefen, benötigen wir für die automatische Verarbeitung eine digitale Fassung der Briefe. Wir gehen deshalb kurz auf unseren “Datenlieferanten” Perseus ein (siehe Unterkapitel 2.2.1). Die Daten liegen uns in sogenannten XML-Dateien vor. Das Format beschreiben wir im Unterkapitel 2.2.2 genauer. Abschliessend widmen wir uns im Abschnitt ?? den ersten Verarbeitungsschritten. Hierbei führen wir anhand von Jupyter-Notebooks durch die ersten einfachen Analysemethoden.

2.2.1 Perseus

Die Texte von Cicero stammen aus dem dem *Perseus Digital Library Project*, das seit 1985 darum bemüht ist, Texte aus der griechischen und römischen Antike online zur Verfügung zu stellen (Crane, 1998). Dabei geht das **Online-Portal** über die bloße Bereitstellung der rohen Texte hinaus. Über die Jahre hinweg wurden die griechischen und lateinischen Texte nicht nur digital aufbereitet (Smith et al., 2000), sondern auch mit automatischer Wortartenannotation und Parsing-Informationen versehen, sodass veritable Baumbanken entstanden sind (Bamman et al., 2007). Auch im Bereich der sogenannten *Linked (Open) Data* ist Perseus gut vertreten (Babeu & Dilley, 2021).¹

Für die vier Subkorpora *ad familiares*, *ad Atticum*, *ad Quintum fratrem* und *ad M. Brutum* findet man im **GitHub-Repository** die relevanten XML-Dateien: `phi0474.phi056.perseus-lat1.xml` (*ad familiares*), `phi0474.phi057.perseus-lat1.xml` (*ad Atticum*), `phi0474.phi058.perseus-lat1.xml` (*ad Quintum fratrem*) und `phi0474.phi059.perseus-lat1.xml` (*ad M. Brutum*).

Um die Briefe im Übrigen auffinden zu können, wie sie in der Literatur angegeben sind, empfiehlt es sich, den **Scaife Viewer** zu verwenden. Wenn White also beispielsweise *Fam.* 6.15 zitiert, meint er Buch 6 in *ad familiares*, Brief 15. Leider finden wir aber nur das erste Buch aus *ad familiares* im Scaife Viewer, weshalb wir auf Perseus durchzählen müssen.

2.2.2 Datenformat: XML

Viele Daten, mit denen auch in der Geschichtsforschung gearbeitet wird, liegen uns im sogenannten XML-Format vor. XML steht für *eXtensible Markup Language*. Sie ist eine Auszeichnungssprache, die wir in Textdateien verwenden und üblicherweise mit der `.xml`-Endung abspeichern. XML ermöglicht es uns, Daten hierarchisch zu strukturieren.

¹Für eine umfassende Publikationsliste, siehe <https://www.perseus.tufts.edu/hopper/about/publications>.

Der Standard hat sich seit 1998, als er zum ersten Mal veröffentlicht wurde, etabliert und stetig weiterentwickelt.² Für Textdaten hat sich zudem das sogenannte TEI-XML durchgesetzt. TEI steht für *Text Encoding Initiative*.³ Darauf bauen weitere Standards für verschiedenste Textgattungen auf. EpiDoc⁴ ist beispielsweise eine an TEI angelehnte Version, welche das Erfassen von Inschriften vereinfacht. Liegen die Daten einmal in einem standardisierten XML-Format vor, so ist es ein Leichtes, sie miteinander zu teilen, die Annotationen zu erweitern oder zu veröffentlichen.⁵ Zudem können sie mit bereits existierenden und extra dafür konzipierten eingelesen und maschinell verarbeitet werden.

Als Motivation, auf etablierte Annotationsschemata wie (TEI-)XML zurückzugreifen, steht der *FAIR*-Grundsatz. FAIR ist kurz für:

1. **Findable** wenn wir Daten veröffentlichen, wollen wir das so tun, dass man sie einfach findet.
2. **Accessible** wir wollen, dass die Daten maschinenlesbar sind.
3. **Interoperable** Daten sollen in gängigen, offenen Formaten vorliegen und mit anderen Systemen kompatibel sein.
4. **Reusable** die Daten sollen einfach wiederzuverwenden sein.

Ein weiterer Vorteil, den XML-Dateien bieten, ist deren hoher Grad an Standardisierung. Standards liegen sogenannte *Schemata* zugrunde. Sie definieren, wie eine XML-Datei strukturiert sein muss. Das Praktische daran: Man kann im Zuge der Erstellung einer XML-Datei wiederholt gegen das Schema prüfen und so in Erfahrung bringen, ob die erzeugte Datei *valide* (also gültig) ist. Im gegenteiligen Fall verläuft die Validierung mit einem Fehler, den man anschliessend korrigieren sollte. So stellt man sicher, dass man stets dem Schema folgt und gültiges XML produziert. Das ist wichtig, da ungültige XML-Dateien nicht eingelesen werden können, auch nicht von Python.

Wenden wir uns nun aber dem Aufbau einer XML-Datei zu. Für gewöhnlich steht an erster Stelle einer XML-Datei die Deklaration. Hier spezifizieren wir, um was für eine XML-Datei es sich handelt und welche Version wir verwenden. Es folgen einige Beispiele von Deklarationen:

Code-Beispiel 2.1 Beispiel 1 für eine XML-Deklartion.

```
<?xml version="1.0" encoding="UTF-8"?>
```

Code-Beispiel 2.2 Beispiel 2 für eine TEI-XML-Deklartion.

```
<TEI xml:lang="en" xmlns="http://www.tei-c.org/ns/1.0">
```

²Für weitere Informationen, siehe die Homepage des World Wide Web Consortiums (W3C): <https://www.w3.org/XML/>.

³Eine umfassende Dokumentation dieses Standards ist auf <https://tei-c.org/> zu finden.

⁴Siehe <https://epidoc.stoa.org/>.

⁵Zum Beispiel mit dem *TEI-Publisher*, siehe <https://teipublisher.com/exist/apps/tei-publisher-home/index.html>.

General period	Metal	Weight	Denomination	Date from	BCorAD1	Date to	BCorAD2	Reverse type	Catalogue reference
4th Century AD Roman	Copper Alloy		Nummus	337	AD	340	AD	Uncertain	Uncertain
3rd Century AD Roman	Copper Alloy		Radiate	260	AD	269	AD	Uncertain	Uncertain
3rd Century AD Roman	Billon		Radiate	251	AD	253	AD	Uncertain	Uncertain
Augustus & 1st Century AD Roman	Copper Alloy		Dupondius	43	AD	64	AD	CERES AVGVSTA SC	as RIC I Claudius 110
Augustus & 1st Century AD Roman	Copper Alloy		Dupondius	43	AD	64	AD	CERES AVGVSTA SC	as RIC I Claudius 110
Augustus & 1st Century AD Roman	Copper Alloy		As	43	AD	64	AD	Minerva SC	as RIC I Claudius 100

Tabelle 2.1 Die ersten sechs Zeilen und einige ausgewählte Spalten des Münzdatensets aus Wales.

In den recht kurzen Code-Beispielen 2.1 und 2.2 passiert schon recht viel. Im Ersten definieren wir, dass der folgende Inhalt eine XML-Datei darstellt. Zusätzlich geben wir die Version mit dem Attribut-Namen `version` und die Zeichenkodierung mit `encoding` an. Im Letzteren spezifizieren wir den Inhalt als TEI. Gleichzeitig sagen wir mit `xml:lang`, dass der Text der Datei auf Englisch gehalten ist. `xmlns` definiert den *Namespace* und weist darauf hin, dass die Elemente in dieser XML-Datei zum TEI-Standard gehören.

Was sind nun die Zutaten, die wir für die Repräsentation von Daten in XML brauchen?

1. **Elemente** Elemente sind die Baublöcke von XML-Dateien. Sie erhalten einen Namen (der theoretisch frei wählbar ist) und werden zwischen spitze Klammern `<...>` gefasst. Elemente können in sich geschlossen sein, z. B., `<coin/>` (beachte den Forwardslash vor der abschliessenden Klammer), oder als Start- und End-Tag aufgebaut sein: `<coin>Dupondius</coin>`. Das End-Tag wird hier mit dem Forwardslash markiert und muss gleich heissen wie das Start-Tag.
2. **Attribute** Elemente können Attribute enthalten. Diese spezifizieren das Element genauer. Attribute sind wie Key-Value-Paare in Python-Dictionaries aufgebaut. Sie müssen mit einem Buchstaben oder einem Unterstrich starten. Der Wert muss zwischen doppelten Anführungszeichen stehen und durch ein Gleichheitszeichen abgetrennt sein. Als Beispiel: `<coin denomination="Dupondius"/>`.
3. **Hierarchie** Wie bereits erwähnt, lässt sich die Datenstruktur mit XML hierarchisch repräsentieren. Elemente können beliebig tief verschachtelt werden. Allerdings muss die Reihenfolge beachtet werden. Wenn die Elemente 1, 2 und 3 geöffnet werden, müssen sie in umgekehrter Reihenfolge geschlossen werden, also zuerst 3, dann 2 und schliesslich 1. Würde man nach 3 zuerst 1 schliessen wollen, wäre das XML ungültig.

Wir bedienen uns für die Illustration einer ersten, ganz einfachen XML-Struktur eines Datensatzes aus der Antike: *Iron Age and Roman Coins from Wales* von der University of Wales. Das Datenset ist frei auf *Archaeology Data Service* verfügbar.⁶ Der Datensatz (als .csv-Datei) sieht unter der Weglassung einiger Spalten aus wie in Tabelle 2.1. Eine Münze aus diesem Datenset finden wir in Abbildung 2.1.

Wir verwenden jetzt die oben erwähnten Zutaten und adaptieren also erstes einmal eine Münze als XML-Struktur:

⁶Siehe <https://doi.org/10.5284/1000263>.



(a) Vorderseite



(b) Rückseite

Abbildung 2.1 Münze des Nero (As) aus dem Jahr 65 n. Chr. (RIC I Nero 416).**Code-Beispiel 2.3** Teil eines Münzdatensets als XML-Struktur.

```
<?xml version="1.0" encoding="UTF-8"?>
<coins>
  <coin id="6">
    <weight unit="g">5.41</weight>
    <denomination>Dupondius</denomination>
    <issuer>Claudius I</issuer>
    <date from="43" to="64"/>
    <reverse_type>CERES AVGVSTA SC</reverse_type>
  </coin>
  <coin id="4">
    <weight unit="g">6.49</weight>
    <denomination>As</denomination>
    <issuer>Agrippa (Gaius)</issuer>
    <date from="43" to="64"/>
    <reverse_type>Neptun SC</reverse_type>
  </coin>
</coins>
```

Wir sehen, wie die verschachtelte Struktur funktioniert. Wir können uns das Element `<coins>` als Liste vorstellen, in welcher wir alle Münzen sammeln. Jeder `<coin>` in dieser Liste ist eindeutig durch seine `id` identifizierbar. Was darauf folgt, sind weitere Eigenschaften der jeweiligen Münze. Der Datensatz wäre auch viel flacher strukturierbar:

Code-Beispiel 2.4 Teil eines Münzdatensatz als XML-Struktur.

```
<?xml version="1.0" encoding="UTF-8"?>
<coins>
  <coin id="6" weight="5.41g" denomination="Dupondius" issuer="
Claudius I" date_from="43" date_to="64" reverse_type="CERES AVGVSTA
SC"/>
  <coin id="4" weight="6.49g" denomination="As" issuer="Agrippa (
Gaius)" date_from="43" date_to="64" reverse_type="Neptun SC"/>
</coin>
</coins>
```

Code-Beispiel 2.4 zeigt, wie im Prinzip alle Elemente aus Code-Beispiel 2.3 auch als Attribute definiert werden können. Das erfordert jedoch eine leichte Umstrukturierung (beispielsweise des Datums oder des Gewichts). Benutzen wir den XML-Standard, sind wir bei der Gestaltung der Datenstruktur relativ frei.

In der Numismatik hat sich jedoch das *Numismatic Description Schema* (NUDS) etabliert. Es orientiert sich ebenfalls am TEI-Standard. Ein einfacher Eintrag für bloss eine Münze kann mit diesem Schema auf gut über 100 Zeilen anschwellen. Vor allem den Metadaten kommt ein grösseres Gewicht zu. Hier ist ein Auszug einer Münze aus dem 2. Jhr. v. Chr., die den Herakles zeigt:⁷

Code-Beispiel 2.5 Münze ‘Price 2051’ im NUDS-XML-Format. Die Punkte zu Beginn und am Ende dieses Beispiels weisen auf die Unvollständigkeit hin.

```
...
<typeDesc>
  <objectType xlink:type="simple" xlink:href="http://nomisma.
  org/id/coin">Coin</objectType>
  <dateRange>
    <fromDate standardDate="-0200">200 BCE</fromDate>
    <toDate standardDate="-0196">196 BCE</toDate>
  </dateRange>
  <denomination xlink:type="simple" xlink:href="http://
  nomisma.org/id/tetradrachm">Tetradrachm</denomination>
  <manufacture xlink:type="simple" xlink:href="http://nomisma
  .org/id/struck">Struck</manufacture>
  <material xlink:type="simple" xlink:href="http://nomisma.
  org/id/ar">Silver</material>
  <authority>
    <persname xlink:type="simple" xlink:role="
  statedAuthority" xlink:href="http://nomisma.org/id/alexander_iii">
  Alexander III of Macedon</persname>
  </authority>
  <geographic>
    <geogname xlink:type="simple" xlink:role="mint"
  xlink:href="http://nomisma.org/id/magnesia_ad_maeandrum">Magnesia ad
  Maeandrum</geogname>
  </geographic>
  <obverse>
    <type>
      <description xml:lang="en">Head of beardless
  Heracles right wearing lion skin headdress</description>
      <description xml:lang="de">Kopf des jugendlichen
  Herakles nach r. mit Löwenfellexuvie</description>
      <description xml:lang="fr">Tête d'Héraclès imberbe
  à dr. coiffé d'une dépouille de lion</description>
    </type>
    <persname xlink:type="simple" xlink:role="deity"
  xlink:href="http://nomisma.org/id/heracles">Heracles</persname>
  </obverse>
  ...
```

Das Code-Beispiel 2.5 zeigt die Beschreibung der Münze, nachdem die Metadaten definiert wurden. Wir sehen eine *dateRange* mit den Werten “200

⁷Siehe <https://www.numismatics.org/pella/id/price.2051>.

BCE” bis “196 BCE” oder auch die uns bereits bekannte denomination (hier “Tetradrachme”). Es sind überdies noch material, authority sowie geografische Angaben zum Prägungsort und zur Bildseite der Münze gegeben. Zudem sehen wir viele Attribute, meist mit dem Präfix xlink:. Der Wert dieses Attributs ist dann ein Link, der auf eine Konzept-Seite in NUDS verweist. Beispielsweise verlinkt http://nomisma.org/id/alexander_iii auf die Konzept-Seite Alexander des Grossen (siehe Abbildung 2.2).




Abbildung 2.2 Screenshot der Personenseite Alexander des Grossen auf Numisma.

Da alle Münzen, die unter Alexander dem Grossen geprägt wurden, mit xlink: auf diese Seite verweisen, findet man weiter unten eine Sammlung aller Münzen unter Alexander dem Grossen. Das ist ein Beispiel von *Linked Open Data*, die sich dadurch auszeichnet, dass ein Datensatz mit weiteren Datensätzen aus dem Netz verbunden ist (siehe dazu die “Relations”, die auf Konzeptseite Alexander des Grossen zu finden sind). Dies zeigt die Nützlichkeit der Strukturierung der Daten in XML.

Als Nächstes schauen wir uns noch das eingangs erwähnte EpiDoc XML zur Auszeichnung von Inschriften an. Dafür nehmen wir uns ein Dokument aus den *Inscriptions of Roman Tripolitania 2021*⁸ zur Hilfe. Die Inschrift unter <https://irt2021.inslib.kcl.ac.uk/en/inscriptions/IRT0002.html> ist in TEI-XML strukturiert. TEI zeichnet sich in der Regel dadurch aus, dass zuerst ein `teiHeader`-Element folgt, das sämtliche Metadaten enthält. Im darauffolgenden `text`-Element ist dann der Text verzeichnet. Wenn wir uns einen Ausschnitt aus diesem XML anschauen (wir fokussieren uns auf die ersten fünf Zeilen), sieht dies eher kompliziert aus:

Code-Beispiel 2.6 Teil eines TEI-XMLs zu einer Inschrift.

```
<div type="edition" xml:lang="la" xml:space="preserve">
  <ab>
    <lb n="1"/>
    <persName type="divine" ref="#caelestis"><addName nymRef
      ="domina"><supplied reason="lost">Do</supplied>minae</addName>
```

⁸Siehe <https://irt2021.inslib.kcl.ac.uk/en/>.

```

<name nymRef="Caelestis">Caelesti</name></persName>
<lb n="2"/><w lemma="pro"><supplied reason="lost">pro</
supplied></w> <w lemma="salus">salute</w>
<w lemma="imperator"><expan><abbr>Imp<del rend="erasure
">p</del></abbr><ex>eratorum</ex></expan></w>
<lb n="3"/><persName type="emperor" ref="#marcusaurelius
"><name type="praenomen" nymRef="Marcus"><supplied reason="lost"><
expan><abbr>M</abbr><ex>arci</ex></expan></supplied></name>
<name type="gentilicium" nymRef="Aurelius"><supplied
reason="lost">A</supplied>ureli</name>
<name type="cognomen" nymRef="Antoninus">Antonini</
name></persName> <del rend="erasure"><w lemma="et">et</w></del>
<lb n="4"/><persName type="emperor" ref="#commodus"><del
rend="erasure"><name type="praenomen" nymRef="Marcus"><expan><abbr>
M</abbr><ex>arci</ex></expan></name>
<name type="gentilicium" nymRef="Aurelius">Aureli</name
></del>
<name type="cognomen" nymRef="Commodus"><del rend="
erasure">Commod</del>i</name>
<lb n="5"/><addName nymRef="Augustus"><expan><abbr>Aug<
del rend="erasure">g</del></abbr><ex>ustorum</ex></expan></addName>
</persName>
<del rend="erasure"><w lemma="et"><supplied reason="lost
">e</supplied><unclear>t</unclear></w>
<persName type="emperor" ref="#crispina"><name type="
gentilicium" nymRef="Bruttia"><supplied reason="lost">Brutt</
supplied><unclear>i</unclear><supplied reason="lost">ae</supplied></
name>

```




Abbildung 2.3 Repräsentation der Inschrift auf der Seite zu *Inscriptions of Roman Tripolitana*.

Wir sehen, dass die eigentliche Edition des Textes mit einem `div`-Element beginnt. Danach folgen die einzelnen Zeilen, separiert durch nummerierte Zeilenumbrüche (`lb`). Nun wird der Text wiedergegeben, wobei dieser kräftig

ausgezeichnet ist. Ein Blick auf die Repräsentation dieser Inschrift auf der offiziellen Homepage hilft (siehe Abbildung 2.3). Zudem ist ein Foto der tatsächlichen Inschrift für ein besseres Verständnis hilfreich (siehe Abbildung 2.4).




Abbildung 2.4 Fotografie der Inschrift CIL VIII, 22689 aus Sabratah, Provinz *Africa proconsularis*, datiert zwischen 178 und 195 n. Chr.

Die erste Zeile im XML lautet `<persName type="divine" ref="#caelestis"><addName nymRef="domina"><supplied reason="lost">Do</supplied>minae</addName><name nymRef="Caelestis">Caelesti</name></persName>`. Wir sehen hier zu Beginn eine Beschädigung an einer Inschrift. Das “Do” ist verloren. Im XML wird dies mit einem `supplied`-Element und der Angabe des Grundes hinzugefügt. Auf der Homepage wird dies dann automatisch als “[Do]” gerendert, wobei dies bei der diplomatischen Umschrift als “[..]” wiedergegeben wird.

In Zeile drei wird es noch interessanter: `<persName type="emperor" ref="#marcusaurelius"><name type="praenomen" nymRef="Marcus"><supplied reason="lost"><expan><abbr>M</abbr><ex>ar</ex></supplied></name><name type="gentilicium" nymRef="Aurelius"><supplied reason="lost">A</supplied>ureli</name><name type="cognomen" nymRef="Antoninus">Antonini</name></persName><del rend="erasure"><w lemma="et">et</w>`. Hier ist die Rede vom Kaiser Mark Aurel (121–180). Es wird also der Name “Marci Aureli Antonini” getaggt, obwohl das “Marci” ergänzt werden muss. Gleichzeitig erhält der `persName` ein `ref`-Attribut. Dieses referenziert oder zeigt auf `#marcusaurelius`. Dass dieser String mit einem Hashtag beginnt, bedeutet, dass es in einem anderen Dokument, in dem zum Beispiel Personennamen gesammelt werden, ein Element mit der ID `xml:id="marcusaurelius"` gibt. Unter diesem Element sind dann alle weiteren Informationen wie Lebensdaten, Ernennung zum Kaiser und Links zu externen Wissensressourcen verzeichnet. Das ermöglicht es dann, eine Personenseite wie die Konzeptseite Alexander des Grossen von der Numismatik-Datenbank zu bauen. Wenn mit `ref` und den entsprechenden IDs auf andere XML-Dokumente verwiesen wird, spricht man von einer sogenannten *Stand-off Annotation*. Somit müssen wir nicht an Ort und Stelle alle Infos zu Mark Aurel wiedergeben, sondern können sie gesondert in einem anderen Dokument aggregieren und, wenn immer nötig, wieder ändern. In der Folge können wir immer dann, wenn Mark Aurel erneut in einer Inschrift vorkommt, einfach auf den Eintrag im Personenverzeichnis verweisen. Wichtig ist, dass die IDs eindeutig sind.

Als Letztes betrachten wir noch ein Beispiel aus dem Briefkorpus des Cicero, um den es ja letztendlich geht. Für das XML in Code-Beispiel 2.7 wurde Text aus *ad M. Brutum* entnommen.

Code-Beispiel 2.7 Ausschnitt eines TEI-XMLs aus der Korrespondenz zwischen Cicero und Brutus.

```

...
<text xml:lang="lat">
  <body>
    <div xml:lang="lat" type="edition" n="
urn:cts:latinLit:phi0474.phi059.perseus-lat1">
      <div type="textpart" n="1" subtype="Book">
        <head>LIBER PRIMVS</head>
        <div type="textpart" n="1" subtype="letter">
          <label rend="opener">
            <seg rend="dateline">Scr. eodem die quo ep
. 2a. <date when="-0043">711 (43)</date>.</seg>
            <seg rend="salute">Cicero Bruto salutem</
seg>
          </label>
          <div type="textpart" n="1" subtype="section">
            <p>L. Clodius, tribunus plebis designatus, valde
me diligit vel, ut <foreign xml:lang="greek">e)mfatikw/teron</
foreign> dicam, valde me amat. <reg>quod</reg> cum mihi ita
persuasum sit, non dubito (bene enim me nosti) quin illum quoque
iudices a me amari. <reg>nihil</reg> enim mihi minus hominis videtur
quam non respondere in amore iis a quibus provocere. <reg>is</reg>
mihi visus est suspicari nec sine magno quidem dolore aliquid a suis
vel per suos potius iniquos ad te esse delatum quo tuus animus a se
esset alienior. <reg>non</reg> soleo, mi Brute, quod tibi notum
esse arbitror, temere adfirmare de altero; est enim periculosum
propter occultas hominum voluntates multiplicisque naturas; sed
Clodi animum perspectum habeo, cognitum, iudicatum. <reg>multa</reg>
eius indicia sed ad scribendum non necessaria. <reg>volo</reg> enim
testimonium hoc tibi videri potius quam epistulam. <reg>auctus</reg>
> Antoni beneficio est. <reg>eius</reg> ipsius benefici magna pars a
te est. <reg>itaque</reg> eum salvis nobis
          <pb/>
          vellet salvum.
        </p>
      </div>
      <div type="textpart" n="2" subtype="section">
...

```

Wir halten fest, dass die Briefe in div-Elementen mit texttype="letter" festgehalten werden. Hierbei finden wir den Text in div-Elementen, die als section ausgewiesen werden. Jeder Brief kann also mehrere Sektionen enthalten. Des weiteren finden, falls der Brief datiert ist, ein Segment seg mit einem rend-Attribut dateline. Zudem ist die Anrede als salute gekennzeichnet. Im Text finden wir nur spärliche Annotationen. Auffallend ist die Auszeichnung griechischer Passagen mit dem Element foreign. Zudem finden wir einige Wörter, die durch ein reg-Element ausgezeichnet wurden. Hierbei handelt es

sich um eine normalisierte Schreibweise einer Textstelle.⁹ Leider können wir nicht mehr nachvollziehen, was vor der jetzt im XML stehenden Form im Text stand.

2.3 Erste Verarbeitungsschritte

In diesem Abschnitt gehen wir vom TEI-XML der Perseus-Edition zu einem reproduzierbaren Dataset. Ziel ist es, die Briefe Ciceros nicht nur als “Texte”, sondern als strukturierte Datenbasis zu behandeln.

Am Ende dieses Prozesses steht eine Tabelle mit zentralen Metadaten pro Brief, die als Grundlage für weitere Analysen dient.

2.3.1 Dateien finden

Zunächst sammeln wir alle XML-Dateien aus dem Ordner `data/`. Die Annahme ist, dass sich dieser Ordner im selben Verzeichnis wie das Notebook befindet.

Code-Beispiel 2.8 Alle XML-Dateien im Ordner `data` sammeln.

```
from pathlib import Path

data_dir = Path("data")
xml_files = sorted(data_dir.glob("*.xml"))

len(xml_files)
```

Hier wird bereits ein zentraler Grundsatz deutlich: Statt einzelne Dateien manuell zu öffnen, automatisieren wir den Zugriff. Das ist eine Voraussetzung für Reproduzierbarkeit.

2.3.2 TEI und Namespace

Perseus verwendet TEI-XML. TEI-Dateien besitzen häufig einen sogenannten *Default-Namespace*. Wenn wir XPath-Abfragen durchführen, müssen wir diesen Namespace berücksichtigen.

Code-Beispiel 2.9 Namespace aus der XML-Datei ermitteln.

```
from lxml import etree

parser = etree.XMLParser(recover=True, huge_tree=True)
doc = etree.parse(str(xml_files[0]), parser)
root = doc.getroot()

root.nsmap
```

Wenn in `nsmap` ein Eintrag für `None` erscheint, handelt es sich um den Default-Namespace. Diesen müssen wir später in XPath-Abfragen explizit angeben.

⁹Siehe dazu <https://tei-c.org/release/doc/tei-p5-doc/de/html/ref-reg.html> in der TEI-Dokumentation.

2.3.3 Was ist ein Brief im XML?

In den Perseus-Dateien sind einzelne Briefe als `div`-Elemente mit `subtype="letter"` ausgezeichnet.

Code-Beispiel 2.10 Alle Briefe in einer Datei finden.

```
letter_divs = root.xpath(
    ".//tei:div[@subtype='letter']",
    namespaces={'tei': root.nsmap.get(None)}
)

len(letter_divs)
```

Wir arbeiten hier nicht mit dem sichtbaren Text, sondern mit der hierarchischen Struktur des XML-Dokuments.

2.3.4 Metadaten extrahieren

Ein Brief besitzt mehrere interessante Informationstypen:

- Buchnummer
- Briefnummer
- Datumszeile
- Datumsattribut `date/@when`
- Anrede

Beispielsweise lässt sich die Datumszeile so extrahieren:

Code-Beispiel 2.11 Datumszeile und Datum extrahieren.

```
dateline = ld.xpath(
    ".//tei:seg[@rend='dateline']",
    namespaces=ns
)

date_el = ld.xpath(
    ".//tei:date[1]",
    namespaces=ns
)

date_when = date_el[0].get("when") if date_el else None
```

Hier zeigt sich ein wichtiger Punkt: Nicht jedes Feld ist immer vorhanden. Fehlende Werte gehören zur Datenrealität antiker Überlieferung.

2.3.5 Absender und Empfänger als Heuristik

Oft steht in der Anrede beispielsweise:

Cicero Bruto salutem

oder

M. Cicero S.D. P. Lentulo procos.

Wir verwenden eine einfache Heuristik, um Absender und Empfänger zu trennen:

Code-Beispiel 2.12 Heuristische Extraktion von Absender und Empfänger.

```
def extract_sender_recipient_from_salute(salute):
    if not salute:
        return None, None

    s = salute.strip()

    m = re.search(r"\bS\s*\.\?\s*D\s*\.\?\b", s)
    if m:
        sender = s[:m.start()].strip()
        recipient = s[m.end():].strip()
        return sender, recipient

    parts = s.split()
    if len(parts) < 2:
        return None, None

    return parts[0], parts[1]
```

Dieses Verfahren funktioniert noch nicht fehlerfrei, aber fängt die meisten Fälle ab. Es ist danach an uns, die Daten auf Korrektheit zu überprüfen. Sie ist jedoch für den Beginn ausreichend für erste explorative Analysen. Für genaue Netzwerkvisualisierungen müssen wir diese Methode noch verfeinern.

2.3.6 Vom XML zur Tabelle

Die extrahierten Informationen werden in Dictionaries gespeichert und anschließend in einen **pandas**-DataFrame überführt:

Code-Beispiel 2.13 DataFrame aus Metadaten erzeugen.

```
import pandas as pd

df = pd.DataFrame(rows)
df.head()
```

Hier erfolgt der methodische Übergang:

hierarchisches XML -> flache Tabelle

Beide Repräsentationsformen sind legitim, dienen jedoch unterschiedlichen Analyseformen. Aber was genau ist **pandas**? **pandas** ist eine Python-Bibliothek zur Verarbeitung und Analyse strukturierter Daten. Sie wurde ursprünglich für

statistische und ökonomische Daten entwickelt, wird heute aber in nahezu allen datenorientierten Disziplinen verwendet.

Das zentrale Objekt in `pandas` ist der sogenannte *DataFrame*. Ein *DataFrame* ist konzeptionell nichts anderes als eine Tabelle:

- Zeilen entsprechen Beobachtungen oder Einheiten,
- Spalten entsprechen Variablen oder Merkmalen.

In unserem Fall bedeutet das:

ein Brief = eine Zeile

Absender, Empfänger, Datum, Buchnummer usw. = Spalten

Warum brauchen wir `pandas`? Es gibt drei zentrale Gründe:

1. **Strukturierung** Wir transformieren hierarchisches XML in eine flache, analysierbare Tabellenstruktur.
2. **Filterung und Gruppierung** Wir können sehr einfach Fragen stellen wie:
 - Wie viele Briefe gibt es pro Korpus?
 - Wie viele Briefe sind datiert?
 - Welche Absender kommen am häufigsten vor?
3. **Statistische Grundoperationen** Mittelwerte, Häufigkeiten oder Anteile lassen sich mit wenigen Befehlen berechnen.

Ein *DataFrame* erzeugen Aus einer Liste von Dictionaries entsteht ein *DataFrame* mit einem einzigen Befehl:

Code-Beispiel 2.14 *DataFrame* aus einer Liste von Dictionaries erzeugen.

```
import pandas as pd

df = pd.DataFrame(rows)
df.head()
```

`df.head()` zeigt die ersten Zeilen der Tabelle an. Damit sehen wir sofort, ob unsere Extraktion funktioniert hat.

Typische Operationen mit `pandas` Oft wollen wir Objekte in einem *DataFrame* gruppieren und zählen. Dafür gibt es die `groupby`-Methode:

Code-Beispiel 2.15 Anzahl Briefe pro Korpus.

```
df.groupby("corpus").size()
```

Hier gruppieren wir alle Zeilen nach dem Feld `corpus` und zählen die Anzahl Briefe pro Gruppe.

Des Weiteren wollen wir oft einfache Statistiken wie **Anteile berechnen**. Dazu gibt es in `pandas` weitere integrierte Methoden wie `mean()`:

Code-Beispiel 2.16 Anteil datierter Briefe pro Korpus.

```
df["date_when"].notna().groupby(df["corpus"]).mean()
```

Da True intern als 1 und False als 0 behandelt wird, entspricht der Mittelwert dem Anteil datierter Briefe.

Nachdem uns die Daten als DataFrame vorliegen, können wir die Tabelle relativ simpel auf **fehlende Werte untersuchen**:

Code-Beispiel 2.17 Anteil fehlender Werte pro Feld.

```
df.isna().mean()
```

Hier zeigt sich unmittelbar, welche Felder stabil sind und welche oft fehlen.

Wir sehen, dass pandas nicht einfach ein technisches Hilfsmittel ist. Es zwingt uns zu einer Entscheidung:

Was ist unsere Analyseeinheit?

Indem wir sagen:

Ein Brief ist eine Zeile.

legen wir implizit fest, auf welcher Ebene wir argumentieren. Gleichzeitig verlieren wir dabei bestimmte Aspekte der hierarchischen Struktur des XML. Ein DataFrame ist flach. Ein TEI-Dokument ist verschachtelt.

Die Wahl des Datenmodells ist also nicht neutral, sondern bereits eine methodische Entscheidung. Für den Cicero-Briefwechsel ist die hierarchische Struktur nicht zentral, weshalb wir im Prinzip sagen können, dass die Repräsentation als XML gleich jener im DataFrame ist.

Fazit pandas ermöglicht es uns,

- strukturierte Tabellen zu erzeugen,
- schnell quantitative Fragen zu stellen,
- fehlende Daten sichtbar zu machen,
- und Ergebnisse reproduzierbar zu speichern.

Damit bildet es die zentrale Brücke zwischen Textstruktur und quantitativer Analyse.

2.3.7 Datenset exportieren

Code-Beispiel 2.18 Mini-Dataset als CSV speichern.

```
mini_cols = [
    "corpus",
    "book_n",
    "letter_n",
    "sender",
```

```

    "recipient",
    "date_when",
    "year",
    "dateline"
]

mini = df[mini_cols]
mini.to_csv("outputs/cicero_letters_metadata_mini.csv", index=False)

```

Damit entsteht ein kleines, reproduzierbares Dataset, das unabhängig vom Notebook weiterverwendet werden kann.

2.3.8 Erste statistische Checks

Nun prüfen wir die Datenbasis kritisch:

Code-Beispiel 2.19 Briefe pro Korpus.

```
df.groupby("corpus").size()
```

Code-Beispiel 2.20 Anteil datierter Briefe pro Korpus.

```
df["date_when"].notna().groupby(df["corpus"]).mean()
```

Code-Beispiel 2.21 Anteil fehlender Werte.

```
mini.isna().mean()
```

Diese Schritte sind nicht bloss technische Spielerei, sondern Teil der historischen Datenkritik:

- Welche Felder sind stabil?
- Wo fehlen systematisch Informationen?
- Welche Analysen sind dadurch möglich oder eingeschränkt?

Hier greifen Whites *constraints and biases*. Unsere Datenbasis ist durch Überlieferung, Edition und Strukturierung geprägt. Digitale Methoden machen diese Struktur explizit sichtbar.

2.3.9 Visualisierung

Einfache Grafiken helfen, Strukturen schnell zu erkennen:

Code-Beispiel 2.22 Briefe pro Korpus visualisieren.

```
df.groupby("corpus").size().plot(kind="bar")
```

Visualisierungen sind Interpretationsangebote. Sie beruhen auf bestimmten Feldern. Wenn diese Felder unsicher sind, ist auch die Grafik nur so stabil wie ihre Datenbasis.

2.3.10 Fazit

In diesem Abschnitt hast du:

- TEI-XML strukturell analysiert
- zentrale Metadaten extrahiert
- ein reproduzierbares Mini-Dataset erstellt
- erste quantitative Checks durchgeführt

Damit ist die Grundlage gelegt für weiterführende Analysen wie Zeitverläufe, Netzwerke oder räumliche Auswertungen.

Literatur

- Babeu, A., & Dilley, P. (2021). Linked Open Data for Greek and Latin Authors and Works. Verfügbar 23. Februar 2026 unter <https://dlib.nyu.edu/awdl/isaw/isaw-papers/20-9/>
- Bamman, D., Passarotti, M., Crane, G., & Raynaud, S. (2007). A Collaborative Model of Treebank Development. Verfügbar 23. Februar 2026 unter <http://hdl.handle.net/10062/4755>
- Becker, E.-M., & Blom, H. v. d. (2025). Epistolary Communication and Selffashioning: Cicero and Paul in Comparison. In E.-M. Becker, U. Egelhaaf-Gaiser & A. Fürst (Hrsg.), *Handbuch Brief: Antike* (S. 133–148). De Gruyter. Verfügbar 8. Februar 2026 unter <https://www.degruyterbrill.com/document/doi/10.1515/9783110586800-006/html>
- Becker, E.-M., Egelhaaf-Gaiser, U., & Fürst, A. (Hrsg.). (2025). *Handbuch Brief: Antike*. Walter de Gruyter GmbH & Co KG.
- Crane, G. (1998). The Perseus Project and Beyond: How Building a Digital Library Challenges the Humanities and Technology. *D-Lib Magazine*. Verfügbar 23. Februar 2026 unter <https://www.dlib.org/dlib/january98/01crane.html>
- Ebbeler, J. (2010). Letters [_eprint: https://academic.oup.com/book/0/chapter/335880411/chapter-ag-pdf/44442412/book_38681_section_335880411.ag.pdf]. In *The Oxford Handbook of Roman Studies*. Oxford University Press. <https://doi.org/10.1093/oxfordhb/9780199211524.013.0029>
- Egelhaaf-Gaiser, U. (2025). Der Brief als Forschungsfeld in der Klassischen Philologie. In E.-M. Becker, U. Egelhaaf-Gaiser & A. Fürst (Hrsg.), *Handbuch Brief: Antike* (S. 1–30). De Gruyter. <https://doi.org/doi:10.1515/9783110586800-001>
- Hoskin, M. J. J. (2025). Letters and the Study of History. In E.-M. Becker, U. Egelhaaf-Gaiser & A. Fürst (Hrsg.), *Handbuch Brief: Antike* (S. 88–110). De Gruyter. Verfügbar 8. Februar 2026 unter <https://www.degruyterbrill.com/document/doi/10.1515/9783110586800-004/html>
- Manuwald, G. (2014). *Cicero*. Bloomsbury Publishing.
- Manuwald, G. (2025). Die Briefe Ciceros. In E.-M. Becker, U. Egelhaaf-Gaiser & A. Fürst (Hrsg.), *Handbuch Brief: Antike* (S. 796–803). De Gruyter. Verfügbar 8. Februar 2026 unter <https://www.degruyterbrill.com/document/doi/10.1515/9783110586800-065/html>
- Mommsen, T. (1856). *Römische Geschichte* (1. Aufl., Bd. 3). Weidmann.

- Moretti, F. (2013). *Distant Reading*. Verso Books.
- Müller, W. G. (1980). Der Brief als Spiegel der Seele. Zur Geschichte eines Topos der Epistolartheorie von der Antike bis zu Samuel Richardson. *Antike und Abendland*, 26(1), 138–157. <https://doi.org/10.1515/9783110241389.138>
- Rühl, M. (2025). Kommunikationswissenschaft und Konversationsanalyse. In E.-M. Becker, U. Egelhaaf-Gaiser & A. Fürst (Hrsg.), *Handbuch Brief: Antike* (S. 327–336). De Gruyter. Verfügbar 8. Februar 2026 unter <https://www.degruyterbrill.com/document/doi/10.1515/9783110586800-020/html>
- Schwitter, R. (2017). Der tröstende Freund. Epistolare Praxis und kommunikative Verhaltensweise in Cicero's Epistulae ad familiares. *Ciceroniana on line*, 1(2), 369–394.
- Seibert, S. (2025). Brieftheorie. In E.-M. Becker, U. Egelhaaf-Gaiser & A. Fürst (Hrsg.), *Handbuch Brief: Antike* (S. 223–237). De Gruyter. Verfügbar 8. Februar 2026 unter <https://www.degruyterbrill.com/document/doi/10.1515/9783110586800-012/html>
- Smith, D. A., Rydberg-Cox, J. A., & Crane, G. R. (2000). The Perseus Project: a Digital Library for the Humanities. *Literary and Linguistic Computing*, 15, 15–25. <https://api.semanticscholar.org/CorpusID:61092357>
- Viertel, A. (1879). *Die Wiederauffindung von Ciceros Briefen durch Petrarca: eine philologisch-kritische Untersuchung*. Hartung.
- Walter, A. E. (2014). *Späthumanismus und Konfessionspolitik: Die europäische Gelehrtenrepublik um 1600 im Spiegel der Korrespondenzen Georg Michael Lingelsheims* (Bd. 95). Walter de Gruyter GmbH & Co KG.
- White, P. (2010). *Cicero in Letters: Epistolary Relations of the Late Republic*. Oxford University Press.

